



İSTANBUL MEDENİYET ÜNİVERSİTESİ
MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**BIL485 DERİN ÖĞRENME
DÖNEM PROJESİ**

Mervenur Saruç – 22120205055

Aralık, 2025

1. Giriş

Elektrokardiyogram (EKG), kalbin elektriksel aktivitesini zamana bağlı olarak gösteren biyomedikal bir sinyalidir. EKG sinyali; P dalgası, QRS kompleksi ve T dalgası gibi temel bileşenlerden oluşur. Bu bileşenler arasında yer alan R-telesi, QRS kompleksinin en belirgin noktası olup kalp atımının tespit edilmesinde kritik bir rol oynar. R-telesi tespiti; kalp atım hızı hesaplama, ritim analizi ve çeşitli kardiyak rahatsızlıkların değerlendirilmesi gibi birçok klinik ve analitik uygulamanın temelini oluşturmaktadır.

Ancak EKG sinyalleri; gürültü, hareket artefaktları ve sinyal bozulmaları nedeniyle karmaşık bir yapıya sahiptir. Bu durum R-telesinin doğru ve güvenilir şekilde tespit edilmesini zorlaştırmaktadır. Bu çalışmada, EKG sinyalleri üzerinden R-telesi tespitinin gerçekleştirilmesi amaçlanmış ve bu problem hem veri işleme hem de modelleme açısından ele alınmıştır.

2. Problem Tanımı

Bu çalışmada ele alınan problem, bir EKG sinyali içerisindeki R-teplerinin doğru zaman konumlarının otomatik olarak tespit edilmesidir. Problemin girdisi zamana bağlı EKG sinyali iken, çıktısı sinyal üzerindeki R-telesi noktalarının indeksleri veya bu noktalara karşılık gelen etiketlerdir.

R-telesi tespiti problemi, özellikle gürültülü ve düzensiz sinyallerde yanlış pozitif veya kaçırılan tepe (false negative) sonuçlara yol açabilmektedir. Bu nedenle geliştirilen yöntemlerin hem yüksek doğrulukta çalışması hem de farklı EKG sinyallerine genellenebilir olması beklenmektedir. Bu çalışma kapsamında, R-telesi tespitinin güvenilirliğini artırmak amacıyla uygun veri ön işleme adımları ve modelleme yaklaşımları değerlendirilmiştir.

3. Veri Seti

Bu çalışmada EKG sinyalleri için yaygın olarak kullanılan MIT-BIH Arrhythmia veri seti kullanılmıştır. Veri seti, farklı bireylere ait uzun süreli EKG kayıtlarını ve bu kayıtlarda uzmanlar tarafından belirlenmiş R-telesi (QRS kompleksi) etiketlerini içermektedir. Kayıtlar tek kanallı EKG sinyallerinden oluşmakta olup, sinyaller 360 Hz örneklemeye frekansı ile kaydedilmiştir.

3.1 Veri Ön İşleme

Ham EKG sinyalleri, gürültü ve bazal dalgalanmalar içerebildiğinden dolayı modele verilmeden önce çeşitli ön işleme adımlarından geçirilmiştir. İlk olarak, EKG sinyalinde R-telesinin baskın olduğu frekans aralığını izole etmek amacıyla 5–15 Hz bant aralığında bir band-pass filtre uygulanmıştır. Bu adım, kas gürültüsü ve düşük frekanslı bozulmaların azaltılmasını amaçlamaktadır.

Filtreleme işleminin ardından sinyaller, modele uygun hâle getirilmek üzere pencereleme (windowing) yöntemi ile küçük segmentlere ayrılmıştır. Her bir pencere 200 örnek uzunlığında olacak şekilde oluşturulmuş ve pencerelerin merkezine R-tepeşi gelecek biçimde pozitif örnekler hazırlanmıştır. Buna ek olarak, R-tepesinden yeterince uzak bölgelerden rastgele seçilen segmentler negatif örnekler olarak tanımlanmıştır.

Her bir pencere, sinyal genlik farklılıklarının modele etkisini azaltmak amacıyla Z-score normalizasyonu kullanılarak normalize edilmiştir. Bu sayede her segment sıfır ortalama ve birim varyansa sahip olacak şekilde ölçeklendirilmiştir.

Sonuç olarak, ön işleme adımlarının ardından elde edilen veri seti; dengeli sayıda pozitif (R-tepeşi içeren) ve negatif (R-tepeşi içermeyen) segmentlerden oluşan, derin öğrenme modelleri için uygun bir giriş formatına dönüştürülmüştür

4. Yöntem (Methodology)

Bu çalışmada EKG sinyalleri üzerinde R-tepeşi tespiti gerçekleştirmek amacıyla 1 boyutlu evrişimsel sinir ağı (1D CNN) tabanlı bir derin öğrenme modeli kullanılmıştır. 1D CNN mimarileri, zamana bağlı sinyallerdeki yerel örüntülerin yakalama konusunda etkili oldukları için EKG gibi biyomedikal sinyallerin analizinde sıkılıkla tercih edilmektedir.

4.1 Model Mimarisi

Önerilen model, giriş olarak 200 örnek uzunlığında, tek kanallı EKG segmentlerini almaktadır. Model mimarisi iki adet evrişim katmanı, havuzlama (pooling) katmanları ve tam bağlantılı (fully connected) katmanlardan oluşmaktadır.

İlk evrişim katmanı, 1 giriş kanalı ve 16 filtre içerecek şekilde tanımlanmıştır. Bu katman, EKG sinyalindeki ani genlik değişimleri ve temel dalga şekilleri gibi düşük seviyeli özelliklerini öğrenmeyi amaçlamaktadır. Evrişim işleminin ardından ReLU aktivasyon fonksiyonu ve maksimum havuzlama (Max Pooling) uygulanarak sinyal boyutu azaltılmış ve baskın özellikler korunmuştur.

İkinci evrişim katmanı, 32 filtre kullanarak daha yüksek seviyeli ve karmaşık örüntülerin öğrenilmesini sağlamaktadır. Bu aşamada model, QRS kompleksinin genel yapısı gibi daha ayırt edici sinyal özelliklerini temsil edebilmektedir. Benzer şekilde bu katmandan sonra ReLU aktivasyonu ve maksimum havuzlama işlemi uygulanmıştır.

Evrişim katmanlarından elde edilen özellik haritaları düzleştirilerek tam bağlılı katmanlara aktarılmıştır. İlk tam bağlılı katman 64 nörondan oluşmakta olup, bu katmanda öğrenilen özellikler üzerinden karar verme süreci başlatılmaktadır. Aşırı öğrenmeyi (overfitting) azaltmak amacıyla bu aşamada dropout yöntemi kullanılmıştır.

Modelin çıkış katmanı, tek bir nörondan oluşmakta olup sigmoid aktivasyon **fonksiyonu** ile 0 ile 1 arasında bir olasılık değeri üretmektedir. Bu değer, ilgili EKG segmentinin bir R-tepe'si içerip içermediğini ifade etmektedir.

4.2 Çıkış ve Sınıflandırma Yaklaşımı

Model, ikili sınıflandırma problemi olarak ele alınmış olup;

- **1** etiketi R-tepe'si içeren segmentleri,
- **0** etiketi R-tepe'si içermeyen segmentleri temsil etmektedir.

Sigmoid aktivasyonu sayesinde elde edilen olasılık değeri, belirlenen bir eşik değere göre sınıf etiketi olarak yorumlanmıştır.

5. Model Eğitimi

Önerilen 1D CNN modeli, ön işleme adımlarından geçirilmiş ve pencereleme yöntemi ile oluşturulmuş EKG segmentleri kullanılarak eğitilmiştir. Veri seti, modelin genellemeye performansını değerlendirebilmek amacıyla eğitim ve test alt kümelerine ayrılmıştır.

Modelin eğitimi sırasında, ikili sınıflandırma problemi için uygun olan Binary Cross-Entropy (BCE) kayıp fonksiyonu kullanılmıştır. Çıkış katmanında sigmoid aktivasyon fonksiyonu yer aldığı için, modelin ürettiği değerler 0 ile 1 arasında bir olasılık olarak yorumlanmıştır. Optimizasyon sürecinde, derin öğrenme modellerinde yaygın olarak kullanılan Adam optimizasyon algoritması tercih edilmiştir.

Eğitim süreci boyunca model ağırlıkları, kayıp fonksiyonunu minimize edecek şekilde iteratif olarak güncellenmiştir. Her epoch sonunda model performansı izlenmiş ve aşırı öğrenmenin önüne geçebilmek amacıyla dropout mekanizması kullanılmıştır. Eğitim sırasında kullanılan mini-batch yaklaşımı, hesaplama verimliliğini artırmış ve daha kararlı bir öğrenme süreci sağlamıştır.

Sonuç olarak, model eğitim süreci boyunca EKG sinyallerindeki ayırt edici özellikler öğrenilmiş ve R-tepe'si içeren segmentlerin başarılı bir şekilde sınıflandırılması hedeflenmiştir.

6. Değerlendirme Metrikleri

Bu çalışmada R-tepe tespiti problemi, ikili sınıflandırma olarak ele alınmış ve model performansı birden fazla değerlendirme metriği kullanılarak analiz edilmiştir. Sadece doğruluk (accuracy) metriği, özellikle dengesiz sınıfların bulunduğu biyomedikal problemlerde yanıltıcı olabileceğinden, daha açıklayıcı metriklere yer verilmiştir.

Doğruluk (Accuracy), modelin tüm örnekler üzerindeki genel doğru tahmin oranını ifade etmektedir. Ancak R-tepesinin kaçırılması klinik açıdan daha kritik olduğundan, bu metrik tek başına yeterli görülmemiştir.

Kesinlik (Precision), model tarafından R-tepe olarak tahmin edilen örneklerin ne kadarının gerçekten R-tepe olduğunu göstermektedir. Bu metrik, yanlış pozitif tahminlerin (false positive) etkisini değerlendirmek açısından önemlidir.

Duyarlılık (Recall / Sensitivity), gerçek R-tepe içeren örneklerin ne kadarının model tarafından doğru şekilde tespit edildiğini ifade etmektedir. R-peak detection probleminde en kritik metriklerden biridir; çünkü kaçırılan R-tepleri (false negative) kalp atım hızı ve ritim analizini doğrudan olumsuz etkileyebilmektedir.

F1-Skoru, precision ve recall metriklerinin harmonik ortalaması olup, modelin genel sınıflandırma başarısını dengeli bir şekilde değerlendirmektedir. Bu metrik, hem yanlış pozitiflerin hem de kaçırılan R-teplerinin birlikte analiz edilmesini sağlamaktadır.

Bu metrikler sayesinde modelin yalnızca genel başarısı değil, aynı zamanda R-tepesini doğru tespit etme konusundaki güvenilirliği detaylı olarak değerlendirilmiştir.

7. Sonuç

Bu çalışmada, EKG sinyalleri üzerinde R-tepe tespiti problemi ele alınmış ve bu amaçla 1 boyutlu evrişimsel sinir ağı (1D CNN) tabanlı bir derin öğrenme yaklaşımı önerilmiştir. MIT-BIH Arrhythmia veri seti kullanılarak gerçekleştirilen deneylerde, ham EKG sinyalleri uygun ön işleme adımlarından geçirilmiş; bant geçiren filtreleme, normalizasyon ve pencereleme işlemleri uygulanarak model için uygun bir veri yapısı oluşturulmuştur.

Elde edilen sonuçlar, önerilen modelin EKG sinyallerindeki R-tepe içeren segmentleri başarılı bir şekilde ayırt edebildiğini göstermektedir. Özellikle duyarlılık (recall) metriği üzerinden yapılan değerlendirmeler, modelin R-teplerini kaçırma oranının düşük olduğunu ve bu açıdan güvenilir bir performans sergilediğini ortaya koymustur.

Sonuç olarak, 1D CNN tabanlı yaklaşımın EKG sinyallerinde R-tepe tespiti problemi için etkili ve uygulanabilir bir yöntem olduğu görülmüştür. Gelecek çalışmalarda, daha büyük ve çeşitli veri setleri kullanılarak modelin genelleme kabiliyeti artırılabilir; farklı derin öğrenme mimarileri ve gerçek zamanlı uygulamalar üzerine çalışmalar gerçekleştirilebilir.

